

MCDIA503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

Nombre integrante/s:

Luis Díaz

Gonzalo Bouldres

Eduardo Contreras

Curso:

EXPLORACIÓN
INTELIGENTE DE DATOS

Fecha:

05/09/2026

Contenido

I Título del Proyecto	3
II. Descripción del proyecto.....	4
III. Descripción del conjunto de datos	4
IV. Preguntas exploratorias iniciales y supuestos	5
V. Organización prevista del análisis	5
VI. Criterios iniciales de trabajo reproducible	6
VII. Bibliografía	6

SUPERVIVENCIA EN EL TITANIC: EXPLORACION DE FACTORES ASOCIADOS A DATOS.

II. Descripción del proyecto

El proyecto utiliza el dataset Titanic para estudiar, desde una perspectiva exploratoria, cómo se distribuye la supervivencia y qué patrones iniciales aparecen al compararla con características demográficas y del viaje.

El propósito es comprender el problema antes de inferir o modelar, evaluando simultáneamente la calidad del dato. El análisis permitirá identificar variables que merecen profundización y reconocer cómo nulos, categorías y valores extremos condicionan la interpretación. La elección del conjunto es pertinente porque combina variables numéricas, categóricas, binarias y ordinales, además de problemas de completitud, lo que permite aplicar el recorrido de un EDA mínimo viable (Paraíso, 2026b).

III. Descripción del conjunto de datos

La fuente es Titanic.csv, proporcionado por la asignatura (Universidad Andrés Bello, 2026b). La unidad de análisis es un pasajero: 891 registros y 12 variables. Para el proyecto destacan Survived, Pclass, Sex, Age, SibSp, Parch, Fare y Embarked. PassengerId actúa como identificador; Name, Ticket y Cabin aportan información adicional cuya utilidad debe evaluarse. El diagnóstico inicial detecta 177 nulos en Age (19,9 %), 687 en Cabin (77,1 %) y 2 en Embarked (0,2 %), sin filas completamente duplicadas.

- Limitaciones preliminares: Cabin presenta completitud muy baja; Age requiere decisiones explícitas sobre nulos; Pclass se tratará como variable ordinal y las asociaciones se interpretarán de forma descriptiva, no causal.




Figura 1. Calidad mínima y distribuciones iniciales. Fuente: elaboración propia a partir de Titanic.csv; visualizaciones reproducibles en el notebook de trabajo.

La revisión visual muestra que la principal alerta de calidad es Cabin, mientras Age conserva una fracción relevante de datos faltantes. La supervivencia global es 38,4 %. Age se concentra principalmente en edades adultas y Fare exhibe una fuerte asimetría a la derecha, por lo que media y valores extremos deberán interpretarse con cautela.

IV. Preguntas exploratorias iniciales y supuestos

- ¿Cuál es la proporción de supervivencia y cómo cambia según sexo?
- ¿Existen diferencias de supervivencia entre las clases de pasajero?
- ¿Cómo se distribuye Age y qué diferencias descriptivas aparecen entre sobrevivientes y no sobrevivientes, considerando sus valores faltantes?
- ¿Cómo se comporta Fare y qué patrones preliminares presenta respecto de clase y supervivencia?
- ¿El tamaño del grupo familiar, derivado de SibSp y Parch, muestra patrones que convenga profundizar?

Relaciones descriptivas vinculadas a las preguntas exploratorias




Figura 2. Relaciones descriptivas asociadas a las preguntas exploratorias. Fuente: elaboración propia a partir de Titanic.csv; visualizaciones reproducibles en el notebook de trabajo.

Las diferencias observadas por sexo y clase son marcadas y justifican mantener ambas variables en el foco de la exploración. La comparación de Age no muestra, por sí sola, una separación evidente entre grupos, mientras FamilySize sugiere un patrón no lineal que deberá revisarse considerando el tamaño de cada grupo. Estos resultados son pistas exploratorias y no evidencia causal.

Supuestos y alcance: se asumen válidas las codificaciones de Survived y Pclass; los nulos y posibles outliers no se eliminarán ni imputarán automáticamente. La fase se limita a descripción univariada y bivariada, sin pruebas inferenciales ni modelos predictivos. El carácter histórico y observacional del conjunto limita la generalización de los resultados.

V. Organización prevista del análisis

El trabajo seguirá una secuencia trazable: 1) contexto y carga del archivo; 2) inspección de dimensiones, variables y tipos; 3) calidad mínima (nulos, duplicados, rangos y categorías); 4) descriptivos según tipo de variable; 5) distribuciones univariadas; 6) relaciones simples vinculadas a preguntas; 7) variable derivada FamilySize = SibSp + Parch + 1; 8) revisión de posibles outliers y síntesis de hallazgos, limitaciones y próximos pasos. Cada gráfico tendrá una pregunta y una lectura breve (Paraíso, 2026c).

VI. Criterios iniciales de trabajo reproducible

El análisis se mantendrá en un único notebook ejecutable de principio a fin, combinando celdas narrativas, código, salidas y comentarios para responder qué se hizo, por qué y qué se encontró. La estructura de archivos será explícita: data/input/Titanic.csv conservará el dato original; data/process/ almacenará los datos derivados; figures/ contendrá todas las imágenes generadas; y outputs/ reunirá tablas, CSV, resúmenes y el manifiesto de ejecución. Las transformaciones se realizarán por código sobre una copia en memoria y se registrarán ruta de entrada, hash SHA-256, versiones del entorno y reglas de variables derivadas. Toda decisión sobre nulos u outliers quedará documentada antes de aplicarse, manteniendo coherencia y trazabilidad entre datos, transformaciones, figuras y resultados (Paraíso, 2026a).

VII. Bibliografía

- Paraíso, S. (2026a). *Checklist notebook reproducible* [Infografía]. Universidad Andrés Bello.
- Paraíso, S. (2026b). *Resumen aplicado del libro: EDA mínimo viable* [Apunte]. Universidad Andrés Bello.
- Paraíso, S. (2026c). *Tres errores típicos en EDA* [Podcast]. Universidad Andrés Bello.
- Universidad Andrés Bello. (2026a). *Evaluación Formativa 1: Fase 1, Exploración Inteligente de Datos* [Instrucciones y escala de apreciación].
- Universidad Andrés Bello. (2026b). *Titanic.csv* [Conjunto de datos de la asignatura MCDI503].
- Universidad Andrés Bello. (2026c). *EDA mínimo viable con el dataset tips* [Jupyter Notebook de implementación, MCDI503].