

MCDI503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

AVANCE DEL PROYECTO FASE 1

EVALUACIÓN SUMATIVA S01

SUPERVIVENCIA EN EL TITANIC: EXPLORACIÓN DE FACTORES ASOCIADOS A DATOS

Nombre integrante/s: Luis Díaz

• Gonzalo Bouldres • Eduardo

Contreras

Curso: MCDI503 • Exploración Inteligente de Datos

Docente responsable: Sergio Paraíso

Fecha: 05/09/2026

II. Introducción y contextualización

El proyecto mantiene el mismo foco definido en la Formativa 1: estudiar, desde una perspectiva exploratoria, cómo se distribuye la supervivencia en Titanic y qué patrones iniciales aparecen al compararla con características demográficas y del viaje. La Sumativa S01 no redefine el proyecto; ejecuta la planificación previa, cuantifica la calidad del dato y genera evidencia reproducible para decidir qué variables y problemas requieren profundización antes de inferir o modelar.

III. Objetivo exploratorio, preguntas iniciales y alcance del avance

Objetivo: ejecutar el EDA planificado en la Formativa 1 para describir la supervivencia y explorar patrones asociados con sexo, clase, edad, tarifa y tamaño familiar, documentando decisiones, transformaciones, supuestos y limitaciones.

1. ¿Cuál es la proporción de supervivencia y cómo cambia según sexo?
2. ¿Existen diferencias de supervivencia entre las clases de pasajero?
3. ¿Cómo se distribuye Age entre sobrevivientes y no sobrevivientes, considerando sus faltantes?
4. ¿Cómo se comporta Fare y qué patrones presenta respecto de clase y supervivencia?
5. ¿El tamaño familiar derivado de SibSp y Parch muestra patrones que convenga profundizar?

Alcance: EDA univariado/bivariado; sin inferencia ni modelos. Se asumen válidas las codificaciones de Survived/Pclass; nulos y outliers no se imputan ni eliminan automáticamente y las asociaciones se interpretan como descriptivas, no causales.

IV. Implementación inicial del EDA en notebook

El notebook ejecuta la secuencia prevista: carga e integridad → estructura/tipos → calidad mínima → descriptivos → distribuciones → relaciones vinculadas a las cinco preguntas → FamilySize → outliers → síntesis. En las secciones III-VI se integra narrativa y código mediante la secuencia pregunta → acción → resultado. La Figura 1 reproduce, ahora como ejecución técnica, el diagnóstico que había sido planificado en la Formativa 1.

Figura 1. Diagnóstico ejecutado: calidad y distribuciones iniciales




Figura 1. Diagnóstico ejecutado: calidad, supervivencia global y distribuciones iniciales. Fuente: elaboración propia desde el notebook (sección III).

Lectura Figura 1. Cabin concentra 77,1 % de ausencia y Age 19,9 %; no hay duplicados completos. La supervivencia global es 38,4 %, Age mantiene una mediana de 28 años y Fare es fuertemente asimétrica. Estos resultados

justifican analizar Age con casos válidos y revisar los valores extremos de Fare sin eliminarlos automáticamente.

V. Documentación trazable de decisiones exploratorias

Decisión	Motivo	Resultado intermedio
Fuente inmutable / sin imputación	Preservar entrada y evitar supuestos prematuros	Age usa casos válidos; Cabin queda fuera del foco
Pclass ordinal	Comparar categorías y no magnitudes	Tasas por clase y cruce con Sex
FamilySize = SibSp + Parch + 1	Ejecutar transformación planificada	Patrón no lineal; IsAlone solo como extensión secundaria
Conservar extremos de Fare	IQR identifica casos altos, no errores	116 casos marcados; ninguno eliminado

VI. Reproducibilidad y coherencia técnica

Se conserva la estructura definida en la Formativa 1: data/input, data/process, figures, notebooks, outputs y Reports. El notebook usa rutas relativas, registra SHA-256 y versiones del entorno, genera datos procesados/figuras/tablas por código y no depende de pasos manuales ocultos.

VII. Registro del proceso, supuestos y limitaciones

Proceso: carga → calidad → descriptivos → relaciones → transformaciones → síntesis. Supuestos: una fila = un pasajero; Survived/Pclass correctamente codificados; FamilySize aproxima el grupo familiar registrado. Limitaciones: Cabin 77,1 % nulo; Age 177 faltantes; Fare asimétrica con extremos; conjunto histórico/observacional; sin causalidad, inferencia ni predicción en S01.

VIII. Hallazgos exploratorios iniciales y referencias al notebook

Figura 2. Ejecución de las cinco preguntas exploratorias de la Formativa 1




Figura 2. Ejecución de las preguntas exploratorias de la Formativa 1. Fuente: elaboración propia desde el notebook (secciones IV-V). La pregunta sobre Fare se profundiza en la Figura 3.

Lectura Figura 2. La supervivencia cambia de forma marcada por sexo (74,2 % en mujeres frente a 18,9 % en hombres) y por clase (63,0 % en 1.ª frente a 24,2 % en 3.ª). Age mantiene una mediana de 28 años en ambos grupos y FamilySize muestra un patrón no lineal, con mejores tasas en tamaños 2-4; son asociaciones descriptivas, no causales.

Figura 3. Fare: distribución y patrones respecto de clase y supervivencia




Figura 3. Fare: distribución y patrones respecto de clase y supervivencia. Fuente: elaboración propia desde el notebook (sección IV, Pregunta 4).

Lectura Figura 3. Fare presenta una fuerte asimetría y niveles claramente distintos por clase: la mediana es 60,29 en 1.ª, 14,25 en 2.ª y 8,05 en 3.ª. También es mayor entre sobrevivientes (26,0) que entre no sobrevivientes (10,5), pero esta diferencia debe leerse junto con Pclass y no como una relación causal independiente.

IX. Bibliografía

- Paraíso, S. (2026). Resumen aplicado del libro: EDA mínimo viable [Apunte]. Universidad Andrés Bello.
- Paraíso, S. (2026). Checklist notebook reproducible [Infografía]. Universidad Andrés Bello.
- The pandas development team. (n.d.). pandas documentation. <https://pandas.pydata.org/docs/>
- Bruce, P., Bruce, A., & Gedeck, P. (2020). Practical statistics for data scientists (2nd ed.). O'Reilly Media.