

MCDIA503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

AVANCE DEL PROYECTO FASES 2 Y 3

Evaluación Sumativa 2 · Preparación analítica y patrones iniciales de supervivencia en Titanic

Nombre integrante/s: Luis Díaz / Gonzalo Bouldres / Eduardo Contreras

Curso: 202681.2538 | EXPLORACIÓN INTELIGENTE DE DATOS

Profesor: Sergio Paraíso

Fecha: 16/09/2026

I. Título del avance y foco del proyecto

Preparación analítica y patrones iniciales de supervivencia en Titanic. El foco es consolidar un dataset consistente y trazable para explorar, de forma descriptiva, asociaciones entre supervivencia, sexo, clase, edad, tarifa y contexto familiar. El alcance es exploratorio y no causal. (Notebook, secc. II-III).

II. Contexto del proyecto y descripción del conjunto de datos

Se utiliza el dataset Titanic distribuido por Seaborn (Waskom, 2021), almacenado localmente para asegurar reproducibilidad. La unidad de análisis es un pasajero; el conjunto contiene 891 registros y 15 variables sobre supervivencia, clase, sexo, edad, tarifa, embarque y composición familiar. Su elección permite evidenciar diagnóstico de calidad, limpieza, transformaciones, integración con tablas derivadas y análisis univariado/bivariado. (Notebook, secc. II-III).

III. Diagnóstico de calidad de datos realizado

Campo	Nulos	%	Prioridad	Impacto / criterio
age	177	19,9%	Alta	Variable central; requiere tratamiento explícito
deck	687	77,1%	Media	No es defendible imputar cubierta específica
embarked / embark_town	2	0,2%	Media	Impacto acotado; campos equivalentes
filas duplicadas	0	0%	Baja	No corresponde eliminar registros

Se verificaron completitud, duplicados, validez y consistencia. Las reglas confirmaron $survived \in \{0,1\}$, $pclass \in \{1,2,3\}$, edades y tarifas no negativas y coherencia entre $class/pclass$, $alive/survived$, $embarked/embark_town$ y $alone/composición\ familiar$. La priorización considera el impacto analítico y no solo el porcentaje de ausencia (Paraíso, 2026a, 2026d). Los extremos se investigan antes de clasificarlos como errores. (Notebook, secc. IV).




Figura 1. Porcentaje de valores faltantes por variable. Fuente: elaboración propia; reproducible en Notebook IV.

IV. Limpieza, validación e integración de datos

Campo	Acción aplicada	Justificación
age	Imputar mediana por sex × class en age_clean y se conserva la bandera age_imputed	Mantiene contexto de subgrupo; bandera age_imputed
embarked	Completar 2 ausencias con la moda	Volumen mínimo; sincronizar embark_town
deck	Recodificar ausencias como Unknown	77,1% missing: no se inventa una cubierta
outliers	Conservar y documentar	Eliminar solo si existe evidencia de error

Se aplicó una limpieza conservadora y trazable (Paraíso, 2026c): age se imputa con la mediana de sex × class en age_clean y se conserva la bandera age_imputed; las dos ausencias de embarked/embark_town se completan con la moda; deck se recodifica como Unknown sin inventar una cubierta. Para evidenciar integración, el dataset se separó en tablas derivadas core/contexto y se unió por row_id con validate="one_to_one": 891 filas antes y después, 891 coincidencias, 0 left_only y claves únicas. (Notebook, secc. V).

V. Transformaciones aplicadas y preparación analítica del dataset

Se generaron family_size, family_group (Solo / Pequeña 2-4 / Grande 5+), age_group y fare_log1p; además, who_clean y adult_male_clean se recalculan después de imputar edad. La versión preparada conserva 891 filas, incorpora 21 columnas y se exporta a data/process/titanic_f23_prepared.csv. Cada transformación responde a una necesidad analítica explícita y queda documentada. (Notebook, secc. VI).

VI. Análisis univariado y bivariado desarrollado

Se combinan media, mediana, cuartiles e IQR con histogramas y boxplots (Paraíso, 2026b, 2026e). CER - Claim: fare presenta una distribución fuertemente asimétrica a la derecha. Evidence: mediana 14,45, media 32,20, IQR 23,09 y cola derecha visible. Reasoning: la diferencia entre media y mediana, junto con la cola, indica concentración en tarifas bajas y pocos valores altos; por ello mediana e IQR describen mejor el centro y la dispersión. age_clean presenta mediana 26 años e IQR 14,5. (Notebook, secc. VII).




Figura 2. Distribuciones de edad preparada y tarifa. Fuente: elaboración propia; reproducible en Notebook VII.

VI. Análisis univariado y bivariado desarrollado (continuación)

CER - Claim: la supervivencia observada difiere de forma marcada por sexo y clase. Evidence: 74,2% en mujeres frente a 18,9% en hombres; 63,0% en primera clase, 47,3% en segunda y 24,2% en tercera. El cruce sexo × clase mantiene diferencias visibles entre estratos. Reasoning: la persistencia del patrón en las comparaciones y el heatmap respalda una asociación descriptiva entre estas variables y la supervivencia, sin atribuir causalidad. El grupo familiar también muestra una estructura no lineal: 57,9% en grupos pequeños, 30,4% en viajeros solos y 16,1% en grupos grandes. (Notebook, secc. VIII).




Figura 3. Supervivencia observada por sexo y por cruce sexo × clase. Fuente: elaboración propia; Notebook VIII.




Figura 4. Supervivencia por grupo familiar y revisión de extremos de tarifa por clase. Fuente: elaboración propia; Notebook VIII-IX.

VII. Patrones, anomalías y hallazgos iniciales

CER - Claim: los valores extremos detectados en fare y age_clean son, en su mayoría, observaciones plausibles y no errores evidentes. Evidence: la regla $1,5 \times \text{IQR}$ identifica 116 extremos en fare (13,0%) y 33 en age_clean (3,7%); las tarifas son no negativas, las edades permanecen en rangos humanos plausibles y los valores altos de fare se concentran especialmente en clases de mayor precio. Reasoning: un extremo estadístico no implica invalidez; al ser coherente con el contexto se conserva y documenta, evitando eliminar señal analítica (Paraíso, 2026e). Deck, en cambio, se mantiene como ausencia informativa (Unknown). (Notebook, secc. IX).

VIII. Decisiones metodológicas, supuestos y limitaciones del avance

Se privilegia una preparación conservadora: medir antes de transformar, registrar banderas de imputación, validar cada integración y no eliminar outliers sin evidencia de error. La imputación de edad por mediana sex × class es una aproximación operativa: reduce la pérdida de casos, pero no recupera el valor real y puede disminuir la variabilidad. (Notebook, secc. X).

El dataset es histórico y observacional; por tanto, las asociaciones no permiten inferir causalidad. Fare puede reflejar estructuras de ticket no modeladas y alive replica semánticamente a survived, por lo que deberá excluirse de un eventual modelamiento para evitar fuga de información. La continuidad propuesta es profundizar interacciones multivariadas y evaluar sensibilidad con y sin imputación de edad. (Notebook, secc. X-XI).

IX. Bibliografía

- Paraíso, S. (2026a). *10 checks de calidad* [Infografía]. Universidad Andrés Bello.
- Paraíso, S. (2026b). *Diseño visual* [Infografía]. Universidad Andrés Bello.
- Paraíso, S. (2026c). *Pandas limpieza + joins* [Apunte]. Universidad Andrés Bello.
- Paraíso, S. (2026d). *Reglas de calidad* [Apunte]. Universidad Andrés Bello.
- Paraíso, S. (2026e). *Relaciones y análisis visual* [Apunte]. Universidad Andrés Bello.
- Paraíso, S. (2026f). *Señales rojas de calidad* [Podcast]. Universidad Andrés Bello.
- Universidad Andrés Bello. (2026). *Evaluación Sumativa 2: Avance del proyecto Fases 2 y 3* [Instrucciones y rúbrica].
- Waskom, M. L. (2021). *seaborn: Statistical data visualization*. Journal of Open Source Software, 6(60), 3021. <https://doi.org/10.21105/joss.03021>