

MCDI503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

Análisis exploratorio de variables asociadas a la supervivencia de pasajeros del Titanic

Nombre integrante/s:

Gonzalo Bouldres

Eduardo Contreras

Luis Díaz

Curso:

EXPLORACIÓN INTELIGENTE
PARA LA CIENCIA DE DATOS

Fecha: 06/09/2026

I. Título tentativo del proyecto

Título tentativo: *Análisis exploratorio de variables asociadas a la supervivencia de pasajeros del Titanic.*

Relación y coherencia: *El título delimita el foco descriptivo del proyecto y se vincula directamente con la variable de supervivencia y con atributos demográficos, socioeconómicos y familiares disponibles en el dataset seleccionado.*

II. Descripción del proyecto

El proyecto aborda los registros del dataset Titanic distribuido mediante Seaborn con el propósito de establecer una base reproducible para explorar asociaciones descriptivas entre la supervivencia y variables como sexo, clase, edad, tarifa y características familiares. El valor esperado es organizar evidencia inicial que permita comprender la estructura del problema y orientar decisiones posteriores de tratamiento y análisis, sin atribuir causalidad. Su relevancia radica en establecer un diagnóstico técnico y trazable del dataset antes de procedimientos inferenciales o predictivos, coherente con el rol del análisis exploratorio como etapa de comprensión y formulación de preguntas (Bruce et al., 2020).

III. Descripción del conjunto de datos

- **Fuente del conjunto de datos:** Se utiliza titanic, distribuido mediante la biblioteca Seaborn (Waskom, 2021). La copia local auditada se conserva sin sobrescritura para asegurar continuidad y trazabilidad.
- **Unidad de análisis:** Cada fila corresponde a un registro de pasajero contenido en el dataset.
- **Variables relevantes:** supervivencia (survived), clase (pclass), sexo (sex), edad (age), tarifa (fare) y variables familiares (sibsp, parch).
- **Observaciones iniciales:** La caracterización técnica reproducible documentada en el notebook identifica 891 registros y 15 variables. Se observan valores faltantes en age (177; 19,87 %), deck (688; 77,22 %), embarked (2; 0,22 %) y embark_town (2; 0,22 %). También se registran 107 filas posteriores completamente coincidentes según el criterio de coincidencia completa aplicado en pandas.
- **Limitaciones preliminares:** El dataset no incorpora un identificador individual único, por lo que las filas completamente coincidentes no se interpretarán automáticamente como pasajeros duplicados. Los faltantes y posibles valores extremos deberán diagnosticarse antes de definir cualquier tratamiento. El alcance se restringe a los registros disponibles y a una interpretación descriptiva.

IV. Preguntas exploratorias iniciales y supuestos

Preguntas exploratorias:

- P1. ¿Cuál es la proporción observada de supervivencia y cómo varía descriptivamente según sex?
- P2. ¿Existen diferencias descriptivas de supervivencia entre las categorías de pclass y cómo se comportan al considerar conjuntamente sex y pclass?
- P3. ¿Cómo se distribuye age y qué diferencias descriptivas pueden evaluarse entre sobrevivientes y no sobrevivientes?
- P4. ¿Cómo se comporta fare respecto de pclass y survived, y qué valores extremos requieren revisión antes de definir un tratamiento?
- P5. ¿El tamaño del grupo familiar construido a partir de sibsp y parch presenta diferencias descriptivas de supervivencia?

Supuestos, alcance y restricciones: survived = 1 representa supervivencia y survived = 0 no supervivencia; pclass se tratará como ordinal/categorica; los faltantes no se imputarán ni eliminarán sin diagnóstico y justificación; un valor extremo estadístico no se considerará automáticamente un error; y las asociaciones se interpretarán descriptivamente, sin atribución causal. El alcance planificado se limita a caracterización, diagnóstico de calidad y EDA univariado/bivariado.

V. Organización prevista del análisis

El proceso se organizará secuencialmente para que cada acción pueda vincularse con una pregunta y una evidencia verificable:

1. Configuración e integridad: cargar la copia local y verificar su identidad mediante SHA-256.
2. Diagnóstico de calidad: revisar tipos, faltantes, rangos, categorías y coincidencias completas.
3. Descriptivos y preguntas P1-P5: caracterizar distribuciones relevantes mediante comparaciones univariadas y bivariadas.
4. Transformaciones justificadas: evaluar $\text{FamilySize} = \text{sibsp} + \text{parch} + 1$ e IsAlone derivada de FamilySize , manteniendo trazabilidad desde las variables originales.
5. Síntesis y evidencia: exportar tablas y figuras, y documentar la relación entre pregunta, acción, resultado y evidencia junto con las decisiones metodológicas adoptadas.

VI. Criterios iniciales de trabajo reproducible

El proyecto utilizará rutas relativas, conservará el dataset original sin sobrescritura y verificará su integridad mediante SHA-256. Las transformaciones se realizarán exclusivamente por código y los productos derivados se almacenarán por separado. La caracterización tabular se apoyará en pandas (The pandas development team, 2024), mientras que el notebook integrará código y narrativa Markdown para registrar objetivo, supuestos, decisiones y limitaciones. Además, el entorno se documentará mediante archivos de dependencias y un manifiesto de versiones. Esta organización sigue los criterios de reproducibilidad propuestos para la asignatura (Paraíso, 2026).

VII. Bibliografía

- Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical statistics for data scientists: 50+ essential concepts using R and Python* (2nd ed.). O'Reilly Media.
- Paraíso, S. (2026). *Checklist notebook reproducible* [Infografía]. Universidad Andrés Bello.
- The pandas development team. (2024). *pandas documentation*. <https://pandas.pydata.org/>
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>