

UNIVERSIDAD ANDRÉS BELLO

MCDI503 - Exploración Inteligente de Datos

EVALUACIÓN SUMATIVA 1 - FASE 1

Supervivencia en el Titanic: exploración de factores asociados a la supervivencia

Integrantes: Luis Díaz | Gonzalo Bouldres | Eduardo Contreras

Docente: Sergio Paraíso

Fecha: 06 de septiembre de 2026

Dataset: titanic de Seaborn - copia local auditada

Índice

I. Portada e índice	1
II. Introducción y contextualización	2
III. Objetivo exploratorio, preguntas y alcance	2
IV. Implementación inicial del EDA en notebook	3
V. Documentación trazable de decisiones exploratorias	3
VI. Reproducibilidad y coherencia técnica	4
VII. Registro del proceso, supuestos y limitaciones	4
VIII. Hallazgos exploratorios iniciales y referencias al notebook	5
IX. Bibliografía	5

II. Introducción y contextualización

El proyecto aborda la supervivencia de los pasajeros del Titanic mediante un análisis exploratorio de datos (EDA) orientado a caracterizar la calidad del conjunto, describir sus distribuciones y reconocer asociaciones preliminares antes de cualquier procedimiento inferencial o predictivo. Este enfoque permite identificar patrones, valores faltantes y observaciones extremas sin introducir tratamientos que alteren prematuramente la evidencia disponible (Bruce et al., 2020).

Se utilizó el dataset titanic distribuido por Seaborn, conservado como copia local auditada. La fuente contiene 891 registros y 15 variables. La ejecución incorpora controles de integridad mediante SHA-256, de manera que el análisis depende de un insumo identificable y reproducible. Seaborn se emplea como biblioteca de visualización estadística y contexto de distribución del conjunto (Waskom, 2021).

El valor del avance reside en establecer una base técnica verificable para decidir qué variables, problemas de calidad y relaciones descriptivas requieren profundización en fases posteriores. En consecuencia, el análisis se concentra en la descripción y documentación del proceso, evitando inferencias causales.

III. Objetivo exploratorio, preguntas iniciales y alcance del avance

Objetivo exploratorio. Describir la supervivencia de los pasajeros y analizar patrones asociados con sexo, clase, edad, tarifa y tamaño del grupo familiar, considerando las condiciones de calidad que puedan limitar la interpretación.

Preguntas exploratorias:

- ¿Cuál es la proporción de supervivencia y cómo cambia según sexo?
- ¿Existen diferencias de supervivencia entre las clases de pasajero?
- ¿Cómo se distribuye age y qué diferencias descriptivas aparecen según supervivencia?
- ¿Cómo se comporta fare y qué patrones preliminares presenta respecto de clase y supervivencia?
- ¿El tamaño del grupo familiar presenta diferencias descriptivas de supervivencia que convenga profundizar?

Alcance, supuestos y límites iniciales. El trabajo corresponde a EDA univariado y bivariado. survived se trata como variable binaria y pclass como ordinal categórica. Los faltantes y extremos se diagnostican antes de adoptar tratamientos. No se realizan imputaciones, pruebas inferenciales ni modelos predictivos; las asociaciones se interpretan de manera descriptiva y no causal.

IV. Implementación inicial del EDA en notebook

El notebook notebooks/mcdi503_f1_sumativo_grupo6.ipynb constituye la evidencia computacional principal. Integra celdas narrativas y código en una secuencia explícita: carga e integridad → estructura y calidad → descriptivos → preguntas exploratorias → transformaciones → visualizaciones → trazabilidad → síntesis → validación. La documentación sigue los principios de ejecución reproducible trabajados en la asignatura (Paraíso, 2026).

La carga se realiza exclusivamente desde data/input/titanic_seaborn.csv; posteriormente se examinan tipos, faltantes, cardinalidad, rangos y categorías. Los bloques P1-P5 implementan las cinco preguntas y generan sus tablas y figuras. Las transformaciones FamilySize = sibsp + parch + 1 e IsAlone se realizan mediante código, conservando las 15 variables originales. Aunque el dataset de Seaborn incluye la variable derivada alone, IsAlone se recalcula explícitamente desde FamilySize para que esta transformación sea auditable desde sibsp y parch. Las operaciones tabulares se implementan con pandas 2.2.2 y quedan materializadas en data/process/ y outputs/ (The pandas development team, 2024).

Correspondencia técnica:

- P1: supervivencia global y por sexo → Figuras 1-2 y supervivencia_por_sexo.csv.
- P2: supervivencia por clase y cruce sexo × clase → Figura 2 y dos tablas de salida.
- P3: edad, faltantes y supervivencia → Figuras 1-2 y age_por_supervivencia.csv.
- P4: tarifa, IQR, clase y supervivencia → Figuras 1 y 3 y cuatro tablas específicas.
- P5: FamilySize e IsAlone → Figura 2 y dos tablas de resultados.

V. Documentación trazable de decisiones exploratorias

La sección V del notebook registra las decisiones D1-D7 con su fundamento y resultado intermedio. La tabla siguiente resume las decisiones que determinan el tratamiento de esta fase; la evidencia completa se conserva en outputs/decisiones_exploratorias.csv.

ID	Decisión	Fundamento / efecto
D1	Copia local auditada	Controlar identidad del insumo mediante SHA-256 y evitar dependencia externa.
D2	No imputar faltantes	Diagnosticar primero la magnitud y distribución de ausencias.
D3	pclass ordinal categórica	Interpretar sus valores como clases y no como magnitud continua.
D4	Crear FamilySize	Integrar sibsp y parch en una medida reproducible del grupo familiar.
D5	Crear IsAlone	Comparar viajar solo frente a registrar al menos un familiar.
D6	Conservar extremos de fare	El criterio IQR identifica extremos estadísticos, no errores demostrados.
D7	Conservar filas coincidentes	Sin identificador individual único no puede confirmarse que correspondan al mismo pasajero.

VI. Reproducibilidad y coherencia técnica

La ejecución definitiva finalizó sin errores y registró estado_global=OK y VALIDACIÓN FINAL: OK. El manifiesto conserva fecha, identidad del insumo, dimensiones y versiones del entorno. El SHA-256 verificado fue 43af81a01f25a7771c9a42809a31625f4d0de3f335cdf29961f9ba179a86c13d. La entrada contiene 891×15 y el procesado 891×17 , incorporando únicamente FamilySize e IsAlone.

La validación automática comprueba conservación de registros, consistencia de las dos variables derivadas, reproducción del archivo procesado, conservación de las 15 columnas originales, concordancia de las tablas de supervivencia exportadas, coherencia de conteos e IQR, y existencia de todos los productos derivados. El entorno registrado fue Python 3.12.4, NumPy 1.26.4, pandas 2.2.2, Seaborn 0.13.2 y Matplotlib 3.8.4; requirements.txt y environment.yml reproducen estas versiones principales.

Para preservar la identidad del dataset también se incorpora .gitattributes, que evita la normalización de finales de línea del CSV auditado al versionarlo con Git. La carpeta .ipynb_checkpoints se excluye mediante .gitignore.

VII. Registro del proceso, supuestos y limitaciones

Proceso seguido:

- verificación de integridad y carga local;
- caracterización de estructura, tipos, faltantes, rangos y categorías;
- análisis descriptivo asociado a P1-P4;
- derivación de FamilySize e IsAlone y análisis P5;
- visualización integrada y registro de decisiones;
- síntesis pregunta-acción-resultado-evidencia y validación final.

Limitaciones documentadas. age presenta 177 valores faltantes (19,9 %) y deck 688 (77,2 %). La regla IQR identifica 116 observaciones extremas de fare, que se conservan. Se registran 107 filas completamente coincidentes; al no existir un identificador individual único en esta versión del dataset, no se eliminan automáticamente. El conjunto es histórico y observacional, por lo que los patrones no sustentan causalidad ni generalización inferencial.

Continuidad. Las decisiones de imputación, selección de variables, tratamiento definitivo de ausencias y eventual análisis inferencial o predictivo quedan reservadas para fases posteriores y deberán justificarse con base en los hallazgos de este diagnóstico.

VIII. Hallazgos exploratorios iniciales y referencias al notebook

Los hallazgos se sintetizan a partir de la corrida definitiva. La evidencia detallada se encuentra en el notebook, sección VI (matriz P1-P5), en las Figuras 1-3 y en `outputs/tabla_pregunta_accion_resultado.csv`.

P	Resultado principal	Interpretación descriptiva
P1	Supervivencia global 38,4 %; mujeres 74,2 % y hombres 18,9 %.	Existe una diferencia descriptiva marcada por sexo; no se interpreta causalmente.
P2	1.ª clase 63,0 %; 2.ª 47,3 %; 3.ª 24,2 %.	La supervivencia disminuye entre las categorías de clase; el cruce sexo × clase aporta contexto adicional.
P3	177 faltantes de age (19,9 %); mediana 28 años en sobrevivientes y no sobrevivientes.	La mediana no diferencia ambos grupos; el análisis se restringe a edades observadas.
P4	Mediana fare 14,45; 116 extremos IQR; medianas por clase 60,29 / 14,25 / 8,05.	fare es fuertemente asimétrica y está asociada a pclass; los extremos se conservan.
P5	Solo: 30,4 %; con familiares: 50,6 %. FamilySize=4: 72,4 % (n=29).	Se observa un patrón no lineal; las tasas deben interpretarse junto con el tamaño de cada grupo.

En conjunto, sexo y clase muestran las diferencias descriptivas más claras; age no presenta separación en la mediana, mientras que fare requiere interpretación conjunta con clase. FamilySize aporta información adicional, pero sus categorías menos frecuentes deben evaluarse con cautela por sus tamaños muestrales reducidos.

IX. Bibliografía

- Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical statistics for data scientists: 50+ essential concepts using R and Python* (2nd ed.). O'Reilly Media.
- The pandas development team. (2024). *pandas 2.2.2 documentation*.
<https://pandas.pydata.org/pandas-docs/version/2.2.2/>
- Paraíso, S. (2026). *MCDI503 Exploración Inteligente para la Ciencia de Datos: material de la Semana 1* [Material docente]. Universidad Andrés Bello.
- Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
<https://doi.org/10.21105/joss.03021>