

MCDI503

EXPLORACIÓN INTELIGENTE DE DATOS

AVANCE DEL PROYECTO FASES 2 Y 3

Evaluación Formativa 2 · Diagnóstico de calidad y preparación inicial del dataset Titanic

Nombre integrante/s: Luis Díaz / Gonzalo Bouldres / Eduardo Contreras

Curso: 202681.2538 | EXPLORACIÓN INTELIGENTE DE DATOS

Profesor: Sergio Paraíso

Fecha: 16/09/2026

I. Título del avance y foco del proyecto

Diagnóstico y preparación del dataset Titanic para analizar factores asociados a la supervivencia de pasajeros. El avance integra calidad de datos, preparación y planificación del análisis exploratorio, sin realizar aún inferencia causal ni modelamiento predictivo.

II. Contexto del proyecto y conjunto de datos

Se trabaja con el dataset Titanic incluido en la librería seaborn (Waskom, 2021), obtenido mediante `seaborn.load_dataset('titanic')`. La versión utilizada contiene 891 registros y 15 variables; **cada registro representa a un pasajero**. Incluye variables numéricas continuas y discretas (*age*, *fare*, *sibsp*, *parch*), categóricas (*pclass*, *sex*, *embarked*, *class*, *who*) y booleanas derivadas (*adult_male*, *alone*). El propósito es preparar una base consistente para explorar posteriormente la relación de la supervivencia con sexo, clase, edad, tarifa, puerto de embarque y composición familiar.

Las variables prioritarias son *survived*, *pclass*, *sex*, *age*, *sibsp*, *parch*, *fare* y *embarked*. *alive* se conserva solo para verificación cruzada y no se utilizará como explicativa por duplicar semánticamente a *survived*, evitando fuga de información.

III. Diagnóstico inicial de calidad de datos

El diagnóstico identificó 869 celdas con valores ausentes y 107 filas duplicadas exactas. Entre las variables con ausencia destacan *deck*: 688 (77,2 %); *age*: 177 (19,9 %); *embarked*: 2 (0,2 %); y *embark_town*: 2 (0,2 %). También se revisaron dominios, valores negativos y observaciones extremas en *age* y *fare* mediante el criterio del rango intercuartílico (IQR).

Estos problemas presentan distinto impacto analítico: la ausencia en *age* puede modificar la caracterización de distribuciones y comparaciones por edad, mientras que la elevada ausencia en *deck* limita su utilización directa. Eliminar automáticamente las 107 filas repetidas podría alterar frecuencias y proporciones sin una clave primaria que permita confirmar duplicación de pasajeros. Por ello, atípicos y registros aparentemente duplicados se marcan y evalúan antes de corregir o excluir (Universidad Andrés Bello, 2026e).

IV. Reglas iniciales de limpieza y validación

Variable	Regla / criterio	Tratamiento inicial
<i>pclass</i>	Dominio {1,2,3}	Marcar y revisar
<i>survived</i>	Dominio {0,1}	Marcar y revisar
<i>age</i>	Edad ≥ 0	Mediana por <i>sex</i> y <i>pclass</i> + indicador
<i>fare</i>	Tarifa ≥ 0	Mediana por <i>pclass</i>
<i>embarked</i>	C, Q o S	Normalizar e imputar con moda; sincronizar <i>embark_town</i>
<i>deck</i>	Alta ausencia permitida (~77%)	No inventar cubierta; recodificar como 'Unknown'
<i>alive</i>	Debe coincidir con <i>survived</i>	No usar como explicativa (fuga de información)
duplicados	Fila exacta repetida	Marcar y revisar manualmente antes de eliminar

V. Estrategia inicial de integración de datos

Se trabaja con una única fuente primaria, correspondiente al dataset Titanic distribuido mediante seaborn, por lo que **en esta fase no resulta aplicable una integración entre fuentes externas**. Las variables derivadas corresponden a transformaciones internas y no se consideran integración de fuentes. Si posteriormente se incorpora una fuente adicional, deberán definirse previamente la clave de unión, la cardinalidad y la compatibilidad estructural y semántica. El foco técnico de esta etapa se concentra, por tanto, en calidad, limpieza, transformación y planificación del análisis exploratorio.

VI. Transformaciones previstas para preparar el dataset

Las transformaciones se realizan sobre una copia del DataFrame original. Se normalizan nombres y categorías, se convierten variables numéricas, se conservan indicadores de ausencia y se generan *family_size*, *is_alone*, *who_clean* y *adult_male_clean*; las dos últimas se recalculan después de imputar *age*. La edad se completa con mediana por sexo y clase; la tarifa con mediana por clase; y *embarked* con la moda cuando corresponde.

Como control posterior se verifica que el número de filas se conserve y que *pclass*, *survived*, *age* y *fare* mantengan dominios consistentes. El dataset preparado se guarda en `data/titanic_preparado_semana2.csv`.

VII. Organización inicial del análisis exploratorio

La exploración se orientará por tres preguntas: ¿la proporción de supervivencia presenta diferencias según sexo y clase?; ¿las distribuciones de edad y tarifa difieren entre sobrevivientes y no sobrevivientes?; y ¿la composición familiar presenta patrones descriptivos respecto de *survived*?

Se desarrollará análisis univariado de *survived*, *sex*, *pclass*, *age* y *fare*, junto con análisis bivariado de *survived* x *sex*, *survived* x *pclass*, *age* x *survived*, *fare* x *survived* y *family_size* x *survived*. Se emplearán frecuencias, proporciones, medidas descriptivas, histogramas, boxplots y barras normalizadas. Además, se revisarán distribuciones asimétricas, valores extremos, diferencias entre grupos y subgrupos potencialmente relevantes, manteniendo una interpretación descriptiva y sin atribuir causalidad (Universidad Andrés Bello, 2026a, 2026c, 2026g).

VIII. Decisiones metodológicas, supuestos y limitaciones iniciales

Decisiones: conservar el dataset original; fijar como fuente el Titanic embebido en seaborn; limpiar sobre una copia; tratar faltantes según su significado; no eliminar atípicos automáticamente; excluir *alive* como explicativa; y mantener una fila por pasajero.

Supuestos: los registros representan pasajeros individuales; las codificaciones principales conservan el significado documentado por la fuente; la ausencia no implica ausencia del fenómeno; y las asociaciones exploratorias se interpretan descriptivamente.

Limitaciones: existen campos con ausencia relevante (*deck* ~77 %); no existe una clave primaria formal explícita ni columnas identificadoras (*name/ticket*) para detectar duplicados parciales; el caso es histórico y específico; la imputación modifica valores y debe permanecer trazable; y esta fase no realiza inferencia causal ni predicción.

Síntesis de trazabilidad y reproducibilidad

El repositorio separa datos, figuras, salidas, notebook e informe. La versión del archivo original queda identificada mediante SHA-256: 43af81a01f25a7771c9a42809a31625f4d0de3f335cdf29961f9ba179a86c13d.

El notebook se conserva como evidencia técnica complementaria: [Abrir notebook ejecutable en GitHub](#).

IX. Bibliografía

- The pandas development team. (s. f.). *pandas documentation*. <https://pandas.pydata.org/docs/>
- Universidad Andrés Bello. (2026a). *De gráfico a argumento (CER)* [Video educativo]. MCDI503.
- Universidad Andrés Bello. (2026b). *Diseño visual* [Infografía]. MCDI503.
- Universidad Andrés Bello. (2026c). *Insights y visualización* [Cápsula docente]. MCDI503.
- Universidad Andrés Bello. (2026d). *Interpretación de gráficos* [Recurso interactivo]. MCDI503.
- Universidad Andrés Bello. (2026e). *Outliers: error vs señal* [Recurso interactivo]. MCDI503.
- Universidad Andrés Bello. (2026f). *Outliers y correlaciones* [Podcast]. MCDI503.
- Universidad Andrés Bello. (2026g). *Relaciones y análisis visual* [Documento guía]. MCDI503.
- Universidad Andrés Bello. (2026h). *Semana 2: Análisis exploratorio e interpretación de datos*. MCDI503.
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>