

MCDIA503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

AVANCE DEL PROYECTO FASES 2 Y 3

Evaluación Sumativa 2: Preparación analítica y patrones iniciales de supervivencia en Titanic

Nombre integrante/s: Luis Díaz | Gonzalo Bouldres | Eduardo Contreras

Curso: 202681.2538 | EXPLORACIÓN INTELIGENTE DE DATOS

Profesor: Sergio Paraíso

Fecha: 17/09/2026

I. Título del avance y foco del proyecto

Preparación analítica y patrones iniciales de supervivencia en Titanic. Objetivo: explorar diferencias por sexo, clase, edad, tarifa y familiares registrados sobre una base validada. Alcance descriptivo, sin modelamiento ni inferencia causal. (*Notebook, I*).

II. Contexto del proyecto y descripción del conjunto de datos

Titanic de Seaborn (Waskom, s. f.) contiene 891 pasajeros y 15 variables. Es un subconjunto histórico, no toda la población a bordo. Sus faltantes, redundancias y variables numéricas/catóricas permiten cubrir preparación y EDA. Se utiliza una copia local con SHA-256 registrado. (*Notebook, II-III*).

III. Diagnóstico de calidad de datos realizado

Campo	Hallazgo	Prioridad / criterio
age	177 ausentes (19,9%)	Alta: variable del foco
deck	688 ausentes (77,2%)	Media: no inferir cubierta
embarked / ciudad	2 ausentes en cada campo	Media: completar ausencias
Perfiles repetidos	107 adicionales; 160 filas involucradas	Alta: no hay ID de pasajero

Los 15 controles no detectan incumplimientos de rangos, categorías o coherencia entre class/pclass, alive/survived, embarque/ciudad, alone/familia, who/edad-sexo y adult_male/who. La ausencia de fallos no descarta errores no observables (Paraíso, 2026b). (*Notebook, IV*).




Figura 1. Faltantes calculados. Elaboración propia; *Notebook IV*.

IV. Limpieza, validación e integración de datos

Se imputan 177 edades con mediana sexo × clase y 2 puertos con moda S; se crea Unknown para cubierta, con versiones nuevas y banderas. Se conservan repeticiones y extremos: sin ID o evidencia de error no se justifica excluirlas (Paraíso, 2026a). who_clean mantiene man/woman/child; cambia 0 casos. (*Notebook, V*).

Las tablas derivadas core/context se unen por row_id con one_to_one: 891 filas antes y después, 891 coincidencias y cero claves sin correspondencia en ambos sentidos. Se validan unicidad, originales y semántica. La clave identifica filas, no personas. (*Notebook, V*).

V. Transformaciones y preparación analítica del dataset

family_size cuenta familiares + pasajero; family_group agrupa 1, 2-4 y 5+; age_group usa <16, 16-34, 35-59 y 60+; fare_log1p comprime la cola sin sustituir fare. El CSV preparado conserva 891 filas, 29 columnas y las 15 originales. (*Notebook, VI*).

VI. Análisis univariado y bivariado desarrollado

Se emplean media, mediana, desviación estándar, cuartiles, IQR, frecuencias, histogramas y boxplots. Las lecturas siguen afirmación-evidencia-razonamiento (CER). (Notebook, VII-VIII).




Figura 2. Edad preparada: distribución y dispersión. Elaboración propia; Notebook VII.

Afirmación: la preparación concentra la edad y reduce su dispersión. **Evidencia:** en 714 edades observadas, mediana 28,0 y desviación estándar 14,53; en 891 edades preparadas, mediana 26,0, IQR 14,5 y desviación 13,30. **Razonamiento:** imputar medianas concentra casos alrededor de valores de grupo; la forma final incluye ese efecto metodológico. (Notebook, VII).




Figura 3. Tarifa original y transformación log1p. Elaboración propia; Notebook VII.

Afirmación: fare es asimétrica a la derecha. **Evidencia:** mediana 14,45, media 32,20 e IQR 23,09; el histograma muestra una cola extensa. **Razonamiento:** las tarifas altas desplazan la media; mediana e IQR describen mejor el centro sin descartar extremos. (Notebook, VII).




Figura 4. Supervivencia por sexo y clase; n indica tamaño del grupo. Elaboración propia; Notebook VIII.

Afirmación: la supervivencia difiere por sexo y clase. **Evidencia:** 74,2% en mujeres y 18,9% en hombres; 63,0%, 47,3% y 24,2% en primera, segunda y tercera. **Razonamiento:** las diferencias por sexo persisten dentro de cada clase, lo que respalda una asociación descriptiva, sin controlar todos los factores ni demostrar causalidad. (Notebook, VIII).

VI. Análisis univariado y bivariado desarrollado (continuación)

Afirmación: la composición del conjunto es desigual. **Evidencia:** 577 hombres (64,8%), 491 pasajeros de tercera (55,1%) y 537 sin familiares registrados; family_size tiene mediana 1 y máximo 11.

Razonamiento: las tasas por grupo deben leerse con sus denominadores, no solo con conteos absolutos. (Notebook, VII).




Figura 5. Supervivencia y familiares registrados. Elaboración propia; Notebook VIII.

Afirmación: la asociación familiar no es monótona. **Evidencia:** 57,9% en grupos pequeños (n=292), 30,4% en solitarios (n=537) y 16,1% en grupos grandes (n=62). **Razonamiento:** el máximo intermedio impide afirmar que más familiares se asocien siempre con mayor supervivencia. (Notebook, VIII).




Figura 6. Edad y tarifa por supervivencia. Elaboración propia; Notebook VIII.

Afirmación: los sobrevivientes presentan mayor tarifa central, pero edades centrales similares.

Evidencia: mediana de tarifa 26,00 frente a 10,50 en no sobrevivientes; mediana de edad preparada 27,0 frente a 25,0 años. **Razonamiento:** los boxplots muestran solapamiento; estas diferencias no separan individualmente a los pasajeros ni prueban un efecto de la tarifa. La edad preparada incorpora imputación. (Notebook, VIII).

Las comparaciones usan tasas con denominadores explícitos y descriptivos por supervivencia exportados. family_size resume parentescos disponibles, no necesariamente todo el grupo de viaje. Las diferencias no permiten predecir individualmente el resultado ni separar el papel de sexo, clase y tarifa. (Notebook, VIII y X).

VII. Patrones, anomalías y hallazgos iniciales




Figura 7. Tarifa por clase; escala symlog, lineal cerca de cero. Elaboración propia; Notebook IX.

Afirmación: los extremos son plausibles, sin evidencia suficiente para excluirlos. **Evidencia:** $1,5 \times \text{IQR}$ detecta 116 tarifas (13,0%) y 33 edades preparadas (3,7%); hay 15 tarifas cero. **Razonamiento:** los valores altos son compatibles con clases de mayor precio; un extremo estadístico no prueba error. Las tarifas cero quedan documentadas para verificar, sin atribuirles una causa. (Notebook, IX).

Con edad observada se detectan 11 extremos entre 714 casos; con edad preparada, 33 entre 891. El límite superior pasa de 64,81 a 57,75 años. Por tanto, el mayor conteo no implica nuevos errores: cambia la distribución de referencia al imputar. (Notebook, VII y IX).

VIII. Decisiones metodológicas, supuestos y limitaciones

La mediana por sexo $\times$ clase aproxima edades faltantes y reduce variabilidad; no demuestra ausencia aleatoria. Unknown y moda no recuperan valores reales. Conservar perfiles iguales evita suprimir pasajeros potencialmente distintos. Se preservan originales, banderas y validaciones. (Notebook, V y X).

El conjunto observacional no permite causalidad ni generalización automática. Fare puede reflejar tickets compartidos; los grupos tienen tamaños desiguales. Alive revela survived y debe excluirse de predictores; class/pclass y otras derivadas requieren controlar redundancia. En futuros modelos la imputación se ajustará solo con entrenamiento. (Notebook, X).

Se consolida una base de 891 filas con diferencias descriptivas por sexo, clase y familia, tarifa asimétrica y extremos conservados. La continuidad es contrastar imputaciones, estudiar interacciones y verificar tarifas cero con una fuente identificable antes de excluir casos. (Notebook, XI).

IX. Bibliografía

Paraíso, S. (2026a). *Pandas limpieza + joins* [Apunte]. Universidad Andrés Bello.

Paraíso, S. (2026b). *Reglas de calidad* [Apunte]. Universidad Andrés Bello.

Universidad Andrés Bello. (2026). *Evaluación Sumativa 2: Avance del proyecto Fases 2 y 3* [Instrucciones y rúbrica].

Waskom, M. (s. f.). *titanic.csv* [Conjunto de datos]. GitHub.

<https://github.com/mwaskom/seaborn-data/blob/master/titanic.csv>