

# MCDI503

## EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

**CIERRE DEL PROYECTO - FASE 4**  
**EVALUACIÓN FORMATIVA**

Plan de ingeniería de variables y selección preliminar de características para el cierre del proyecto Titanic

**Nombre integrante/s:**

Gonzalo Bouldres  
Eduardo Contreras  
Luis Díaz

**Curso:**

EXPLORACIÓN INTELIGENTE  
PARA LA CIENCIA DE DATOS

Fecha: 20/09/2026

## I. Título del avance y foco del pipeline final

Plan de ingeniería de variables y selección preliminar de características para el cierre del proyecto Titanic. El avance se orienta a planificar un pipeline exploratorio reproducible que transforme variables relevantes, incorpore variables derivadas y defina criterios preliminares de selección para una futura etapa de modelamiento, manteniendo el alcance descriptivo y sin atribuir causalidad ni desempeño predictivo.

## II. Contexto del proyecto y objetivo del cierre del proyecto

El proyecto mantiene continuidad con el dataset Titanic distribuido mediante seaborn (Waskom, 2021), compuesto por 891 registros y 15 variables originales. Las Fases 2-3 dejaron una base preparada de  $891 \times 29$  con variables de calidad y derivaciones iniciales, conservando la estructura original y resolviendo tratamientos previos de faltantes. El cierre buscará convertir esa base en una representación candidata, interpretable y trazable para análisis posterior.

Objetivo general: planificar un pipeline de ingeniería de variables y selección preliminar de características, sustentado en los hallazgos del EDA previo y documentado de manera reproducible, de modo que las decisiones puedan ser implementadas y auditadas posteriormente en el notebook final.

## III. Transformaciones y normalizaciones planificadas

| Variable                    | Transformación prevista                          | Propósito                                                                            | Vínculo con EDA previo                                                           |
|-----------------------------|--------------------------------------------------|--------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|
| fare                        | $\log_{10}(\text{fare})$ y posterior z-score     | Reducir asimetría y homogeneizar escala.                                             | Tarifa presenta fuerte cola derecha y máximo de 512,329 frente a mediana 14,454. |
| age_clean                   | z-score                                          | Centrar y escalar la edad preparada sin perder continuidad.                          | Edad preparada conserva 891 casos; $\mu \approx 29,11$ y dispersión relevante.   |
| sex, pclass, embarked_clean | Codificación one-hot con categoría de referencia | Evitar imponer distancias artificiales entre categorías y dejar una matriz numérica. | Son variables categóricas/ordinales relevantes para la supervivencia observada.  |

Las transformaciones se conservarán junto a sus variables de origen durante la auditoría para comparar efectos antes de decidir la matriz candidata definitiva (Kuhn & Johnson, 2019).

## IV. Nuevas variables propuestas

| Variable propuesta | Regla de construcción                 | Valor analítico esperado                                                                                                   |
|--------------------|---------------------------------------|----------------------------------------------------------------------------------------------------------------------------|
| is_minor           | 1 si age_clean < 16; 0 en otro caso.  | Representar explícitamente un umbral etario interpretable.                                                                 |
| sex_pclass         | Combinación de sex y pclass.          | Explorar interacción entre sexo y clase; el EDA previo muestra diferencias marcadas por combinación.                       |
| family_size_sq     | family_size <sup>2</sup> .            | Representar posible relación no lineal; supervivencia previa: 30,4 % solo, 57,9 % familias de 2-4 y 16,1 % familias de 5+. |
| has_family         | 1 si family_size > 1; 0 en otro caso. | Distinguir viajar solo de viajar acompañado con una regla simple e interpretable.                                          |

## V. Criterios preliminares de selección de características

La decisión preliminar considerará relevancia analítica, redundancia, interpretabilidad, consistencia con la preparación previa, calidad del dato, riesgo de fuga de información y utilidad potencial para modelamiento. Se proyecta conservar age\_z, fare\_log1p\_z, pclass, sex, embarked\_clean, family\_size, family\_size\_sq e is\_minor; revisar sex\_pclass, has\_family, age\_imputed, age\_group, family\_group y embarked\_imputed; y descartar alive por fuga directa, row\_id por ser identificador, class por redundancia con pclass, deck por alta ausencia y variables originales reemplazadas por representaciones preparadas. La selección será preliminar y quedará sujeta a validación posterior.

## VI. Estrategia de documentación reproducible del pipeline

El notebook final se organizará en una secuencia explícita: (1) carga y validación de fuentes; (2) revisión inicial; (3) evidencia del EDA que sustenta las decisiones; (4) transformaciones y normalizaciones; (5) variables derivadas; (6) selección preliminar; (7) codificación; (8) construcción de la matriz candidata; y (9) validación y cierre. Cada decisión registrará variable de origen, operación, justificación y efecto esperado.

Para asegurar trazabilidad se utilizarán rutas relativas, registro de versiones de Python y librerías, hashes SHA-256 de fuentes y artefactos, tablas de auditoría para transformaciones/selección, archivos procesados separados del original y un manifiesto de ejecución. El PDF final sintetizará las decisiones y la presentación comunicará los hitos, manteniendo correspondencia explícita con el notebook.

## VII. Decisiones metodológicas, supuestos y limitaciones iniciales

- Decisiones: preservar las 15 variables originales; crear nuevas representaciones sin sobrescribir fuentes; separar survived de las variables predictoras; excluir alive por fuga de información; y revisar interacciones potencialmente redundantes antes de incorporarlas a la matriz candidata.
- Supuestos: survived se utilizará como variable objetivo; la base preparada de Fases 2-3 constituye el punto de partida válido; family\_size representa vínculos familiares registrados a bordo; y las transformaciones derivadas del EDA tienen carácter exploratorio, no causal.
- Limitaciones: dataset histórico y no representativo de otros contextos; 77,2 % de ausencia original en deck; edad previamente imputada; posible inestabilidad en categorías con pocos casos; y ausencia, en esta fase, de validación predictiva fuera de muestra. Por ello, selección preliminar no equivaldrá a selección definitiva.

## VIII. Bibliografía

- Kuhn, M., & Johnson, K. (2019). *Feature engineering and selection: A practical approach for predictive models*. CRC Press.
- McKinney, W. (2010). Data structures for statistical computing in Python. In S. van der Walt & J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56-61). <https://doi.org/10.25080/Majora-92bf1922-00a>
- Universidad Andrés Bello. (2026). *MCDI503 Exploración Inteligente de Datos: materiales de las Fases 2-4* [Material de curso].
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>

Grupo 6 - Luis Díaz | Gonzalo Bouldres | Eduardo Contreras. MCDI503, Fase 4, Evaluación Formativa.