

MCDI503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

CIERRE DEL PROYECTO - FASE 4 EVALUACIÓN SUMATIVA 3

Nombre integrante/s:
Luis Díaz | Gonzalo
Bouldres | Eduardo
Contreras

Curso: 202681.2538 |
EXPLORACIÓN
INTELIGENTE DE
DATOS

Fecha: 23/09/2026

I. Título del avance y foco del pipeline final

Pipeline exploratorio reproducible e ingeniería de variables para el análisis de supervivencia en Titanic. El cierre consolida la base preparada en las Fases 2-3 y construye una representación candidata para modelamiento posterior, con énfasis en transformación, creación de variables, selección preliminar y trazabilidad. El alcance es exploratorio: no se estiman modelos predictivos ni se realizan inferencias causales. (Notebook, I).

II. Contexto del proyecto y objetivo del cierre

Se mantiene el dataset Titanic distribuido mediante seaborn: 891 pasajeros y 15 variables originales. La Sumativa 2 produjo una base preparada de 891×29 ; la Fase 4 parte de esa versión, preserva íntegramente las 15 variables originales y agrega representaciones diseñadas para reducir asimetría, homogeneizar escala y capturar umbrales o relaciones potencialmente no lineales. El objetivo es obtener una matriz candidata consistente, interpretable y libre de fuga directa del objetivo survived. (Notebook, II-III; outputs/01-04).

III. Transformaciones y normalizaciones aplicadas

Variable	Operación	Evidencia observada	Efecto / decisión
fare	log1p	Asimetría 4,787 $\rightarrow$ 0,395	Reduce marcadamente la cola derecha; se conserva fare_log1p_z como candidata.
age_clean	z-score	μ 29,112; σ 13,297 $\rightarrow \mu=0; \sigma=1$	Genera age_z en escala comparable sin perder continuidad.
fare_log1p_f4	z-score	μ 2,962; σ 0,969 $\rightarrow \mu=0; \sigma=1$	Genera fare_log1p_z para una representación centrada y comparable.




Figura 1. Efecto de la transformación log1p sobre fare. Fuente: ejecución Fase 4; Notebook IV.

La reconstrucción fare_log1p_f4 coincide con np.log1p(fare) y con fare_log1p de Fases 2-3, lo que valida la continuidad del pipeline. (outputs/05; outputs/14).

IV. Variables derivadas o creadas

Se incorporaron cuatro variables, cada una con origen, regla y utilidad explícitos: `is_minor` = 1 si `age_clean` < 16; `sex_pclass` = combinación sexo-clase; `family_size_sq` = `family_size`²; y `has_family` = 1 cuando `family_size` > 1. La relación entre tamaño familiar y supervivencia es no monótona; por ejemplo, las tasas son 30,4 % para tamaño 1; 55,3 % para 2; 57,8 % para 3; 72,4 % para 4; 20,0 % para 5 y 13,6 % para 6. Los tamaños 7, 8 y 11 presentan $n \leq 12$ y se interpretan con cautela. Este patrón sustenta explorar un término cuadrático. (Notebook V; outputs/06-07).




Figura 2. Supervivencia observada según tamaño familiar. Fuente: ejecución Fase 4; Notebook V.

La interacción `sex_pclass` mostró una amplitud de 83,3 puntos porcentuales entre combinaciones: 96,8 % en mujeres de 1.ª clase y 13,5 % en hombres de 3.ª clase. Se conserva como variable creada, pero queda en revisión por posible redundancia con `sex` y `pclass`. (outputs/08).

V. Selección preliminar de características

Los criterios de decisión fueron relevancia exploratoria, redundancia, interpretabilidad, consistencia, calidad del dato, fuga de información y utilidad potencial para modelamiento. Se seleccionaron conceptualmente ocho entradas: `age_z`, `fare_log1p_z`, `pclass`, `sex`, `embarked_clean`, `family_size`, `family_size_sq` e `is_minor`. Quedaron en revisión `sex_pclass`, `age_imputed`, `family_group`, `age_group`, `has_family` y `embarked_imputed`. (Notebook VI; outputs/09-10).

Decisión	Variables clave	Fundamento
Seleccionar	<code>age_z</code> ; <code>fare_log1p_z</code> ; <code>pclass</code> ; <code>sex</code> ; <code>embarked_clean</code> ; <code>family_size</code> ; <code>family_size_sq</code> ; <code>is_minor</code>	Representaciones preparadas, interpretables y coherentes con el EDA.
Revisar	<code>sex_pclass</code> ; <code>age_imputed</code> ; <code>family_group</code> ; <code>age_group</code> ; <code>has_family</code> ; <code>embarked_imputed</code>	Pueden aportar información, pero presentan redundancia o riesgo de capturar el proceso de imputación.
Descartar	<code>alive</code> ; <code>row_id</code> ; <code>class</code> ; <code>age/fare</code> originales; <code>deck</code> ; <code>sibsp/parch</code> ; variables redundantes	Evitar fuga, identificadores, alta ausencia, duplicación semántica o sustitución por versiones preparadas o derivadas.

Codificación final: `one-hot` con `drop_first=True`. Referencias: `female` para `sex`, `clase 1` para `pclass` y `C` para `embarked_clean`. Esto evita imponer distancias lineales entre categorías y elimina redundancia perfecta. (outputs/11-12).

VI. Documentación reproducible del pipeline

El notebook registra una secuencia de siete etapas: carga/validación, transformación de tarifa, normalización, ingeniería de variables, selección preliminar, codificación categórica y validación final. La ejecución documenta versiones de Python y librerías, hashes SHA-256 de fuentes y artefactos, reglas de construcción, auditorías de transformación y codificación, decisiones de selección y un manifiesto JSON. (Notebook VII; outputs/00-16; manifest_pipeline.json).

Evidencia	Resultado de la corrida
Controles iniciales	14/14 superados
Validaciones finales	28/28 superadas
Filas preservadas	891 → 891
Columnas originales	15/15 preservadas sin modificación
Matriz candidata	891 × 10; 0 missing; sólo valores finitos
Archivo objetivo	1 identificador (row_id) + 1 variable objetivo (survived), ambos separados de X
Trazabilidad	Hashes SHA-256 + inventario de artefactos + manifiesto JSON

VII. Resultados del pipeline y valor analítico del cierre

La base preparada de Fases 2-3 (891 × 29) se amplió a un dataset enriquecido de 891 × 36 sin alterar los 15 campos originales. La matriz candidata quedó en 891 × 10, sin valores faltantes ni columnas categóricas sin codificar. Las diez columnas son: age_z, fare_log1p_z, family_size, family_size_sq, is_minor, sex_male, pclass_2, pclass_3, embarked_clean_Q y embarked_clean_S. (Notebook VIII; outputs/12-15).

El valor analítico del cierre radica en separar explícitamente el objetivo, controlar fuga de información, reducir la asimetría de tarifa, homogeneizar escala y representar umbrales/no linealidades sin perder trazabilidad. El resultado queda preparado para una etapa posterior de partición train/test, estimación y comparación de modelos, sin atribuir aún desempeño predictivo a las características seleccionadas.

VIII. Decisiones metodológicas, supuestos y limitaciones

Decisiones: preservar variables originales; reconstruir y auditar transformaciones; mantener survived separado de la matriz X; excluir alive por fuga directa; codificar categorías con referencia explícita; y dejar interacciones potencialmente redundantes en revisión. Supuestos: la preparación de Fases 2-3 es válida como punto de partida y family_size representa parentescos registrados a bordo. Limitaciones: caso histórico y no representativo de otros contextos; 77,2 % de ausencia original en deck; imputación previa de age; asociaciones exploratorias no causales; y selección aún preliminar, sin validación mediante desempeño fuera de muestra. (Notebook IX).

IX. Bibliografía

Kuhn, M., & Johnson, K. (2019). *Feature engineering and selection: A practical approach for predictive models*. CRC Press.

McKinney, W. (2010). Data structures for statistical computing in Python. In S. van der Walt & J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56-61). <https://doi.org/10.25080/ajora-92bf1922-00a>

Universidad Andrés Bello. (2026). *MCDI503 Exploración Inteligente de Datos: materiales de las Fases 2-4* [Material de curso].

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>

Correspondencia con la evidencia técnica

El informe sintetiza exclusivamente resultados producidos por el notebook ejecutado. Las transformaciones se documentan en Notebook IV; variables derivadas en V; selección y codificación en VI; trazabilidad en VII; dataset final y validaciones en VIII; y supuestos/limitaciones en IX. Los archivos outputs/05, outputs/10, outputs/11, outputs/14 y outputs/15 constituyen las principales tablas de respaldo.

Grupo 6 - Luis Díaz | Gonzalo Bouldres | Eduardo Contreras. MCDI503, Fase 4, Evaluación Sumativa 3.